

MINERAÇÃO DE DADOS

AVALIAÇÃO DO BIMESTRE

Trabalho Prático + Apresentação Oral

Tipo	Trabalho em dupla + apresentação oral
Tempo de apresentação	6 a 8 minutos por dupla
Entrega	(.ipynb ou .py) + slides (PPTX)

OBS: Os dois membros da dupla deverão fazer a apresentação e entrega do trabalho.

As Bases (Dataset) deverão ser diferentes, ou seja cada dupla, escolherá uma base de dados grande.

1. Objetivo

Aplicar na prática os conceitos de Mineração de Dados e KDD, utilizando Regras de Associação para identificar relações e padrões relevantes em uma base de dados real.

A dupla deverá escolher uma base de dados de grande porte disponível no Kaggle, realizar o tratamento e a preparação dos dados e aplicar um algoritmo de mineração de regras de associação. Os resultados deverão ser interpretados.

2. Escolha da base de dados

A dupla deverá escolher UMA base de dados de grande porte disponível no Kaggle. A base deverá possuir quantidade suficiente de registros para permitir uma análise significativa.

A dupla deverá informar:

- Nome da base de dados;
- Link da base no Kaggle;
- Quantidade de registros;
- Quantidade de colunas;
- Descrição das principais variáveis;
- Qual problema ou situação de negócio pode ser analisado;
- Como os dados poderão ser organizados em transações para aplicação das regras de associação.

Exemplos de temas:

- Vendas
- E-commerce
- Supermercados
- Produtos
- Clientes
- Marketing
- Serviços
- Filmes e entretenimento
- Saúde
- Finanças
- Telecomunicações
- Educação
- Logística
- Turismo
- Redes sociais

Importante: a base deverá permitir a identificação de relações entre itens, produtos, serviços, eventos ou comportamentos. A base escolhida deverá ser aprovada pelo professor antes do desenvolvimento do trabalho.

3. Técnica obrigatória

A dupla deverá utilizar Regras de Associação, podendo escolher entre:

- FP-Growth
- Apriori

A dupla deverá justificar a escolha do algoritmo utilizado.

É permitido e recomendado utilizar:

- Python
- pandas
- mlxtend
- TransactionEncoder
- FP-Growth
- Apriori

4. O que deve conter o trabalho

1. Introdução

- Objetivo do trabalho;
- Apresentação do problema;
- Descrição da base escolhida;
- Fonte da base;
- Quantidade de registros;
- Quantidade de variáveis.

2. Análise e preparação dos dados

- Identificação das principais variáveis;
- Tratamento de dados ausentes, duplicados ou inconsistentes, quando necessário;
- Seleção das variáveis utilizadas;
- Transformação dos dados para o formato de transações;
- Aplicação do TransactionEncoder, quando necessário.

3. Aplicação do algoritmo

- Escolha entre FP-Growth ou Apriori;
- Justificativa da escolha;
- Definição do min_support;
- Geração dos itemsets frequentes.

4. Geração das regras

- Suporte (support);
- Confiança (confidence);
- Lift;
- Justificativa dos parâmetros utilizados, especialmente min_support, min_confidence e min_lift.

5. Resultados

- Apresentar tabelas e/ou gráficos com os principais resultados;
- Selecionar pelo menos 5 regras de associação relevantes para análise.

6. Interpretação dos resultados

- Explicar o significado das regras selecionadas;
- Interpretar os resultados.
- Apresentar pelo menos 5 insights de negócio.

7. Comparação ou justificativa do algoritmo

- Explicar por que o algoritmo escolhido foi utilizado;
- Caso utilize FP-Growth, explicar por que ele é adequado para a base analisada e, quando pertinente, compará-lo conceitualmente com o Apriori.

8. Conclusão

- Principais descobertas;
- Utilidade dos resultados para o negócio;
- Limitações da análise;
- O que poderia ser feito em uma análise futura.